

Indoor Localization Algorithm based on Fingerprint Using a Single Fifth Generation Wi-Fi Access Point

A. R. L. Paiva, W. C. Freitas, I. M. Guerreiro and H. J. B. Nascimento

Abstract— Over recent years, wireless indoor positioning systems (WIPS) have attracted considerable research interest. However, high-performance WIPS proposed in the literature requires that the building have at least three access points (APs). This paper proposes an WIPS using a single fifth-generation (5G) Wi-Fi access point. The proposed method uses beam fingerprints and classification models based on KNN (K-nearest neighbor) and Bayes rule. The beam fingerprint is composed of RSS (Received Signal Strength) samples, collected in some 2D locations of the indoor environment for each beam codebook in the off-line phase. In the online phase, RSS samples of the best beams are collected by user equipment (UE) during the beamtracking process, which are then classified based on beam fingerprints into predefined coordinates. Numerical simulations shown that using the best beam samples, it is possible to locate the stationary user's mobile device with average error less than 2.5 m.

Keywords— localization, indoor, WLAN, beamforming, fingerprint.

I. INTRODUÇÃO

SISTEMAS de posicionamento local (IPS, do inglês *Indoor Positioning System*) são soluções de localização e rastreamento de pessoas e objetos propostas para substituírem o GPS em ambientes fechados [1]. Diferente do GPS, os IPSs utilizam transmissores locais, comumente chamado de *beacons*, e abordam diferentes tipos de sinais, tais como sinal sonoro [2] magnético [3], óptico [4] e de ondas de rádio [5], e diferentes tipos de medições do sinal recebido, tais como potência do sinal, tempo e ângulo de chegada. Além dessas diferenças, alguns IPSs também são capazes de determinar a orientação e pose do usuário [6].

Espera-se que os IPSs e os GPSs, trabalhando em conjunto, possam proporcionar um poderoso sistema de posicionamento com poucas limitações geográficas e com diversos níveis de resolução. Com os dois sistemas trabalhando de forma coordenada, seria possível guiar um usuário de uma rodovia até um produto na prateleira da loja de um shopping. Os IPSs viabilizam os serviços baseados em localização (SBL) dentro de ambientes fechados, tais como [1]:

- Museus, shoppings e lojas: aplicativos de informação e promoções locais, e localização de produtos e serviços para o consumidor;
- Hospitais: rastreamento de profissionais da saúde, pacientes e equipamentos médicos em situações de emergência;
- Transportadoras: localização e rastreamento de pessoas, ativos, mercadorias, cargas, transportes etc.;
- Ambient Assisted Living (AAL): sistemas que prestam assistência para idosos e pessoas em recuperação no conforto de suas casas através de monitoramento de sinais vitais, detecção de situações de emergência e acidentes (*fall detect*) [7];
- Indústrias: robôs autônomos, sistemas cooperativas, entre outros.

Os IPSs podem ser de arquitetura dedicada e não-dedicada. Os de arquitetura dedicada utilizam transmissores e receptores próprios, tais como os IPSs baseados em ultrassom [2] e UWB (*Ultrawideband*) [8]. Estes possuem as vantagens de serem mais robustos e precisos, porém possuem custo mais elevado devido à compra e manutenção desses dispositivos. Os de arquitetura não-dedicada utilizam os dispositivos de uma tecnologia já existente, tais como os IPSs baseados em: WLAN (do inglês *Wireless Local Area Networks*) [9], que utilizam os APs (do inglês *Access Point*) e a interface de rede sem fios do equipamento do usuário (UE, do inglês *User Equipment*), luz visível [6], que utilizam as câmeras de vigilância do estabelecimento, e em campo geomagnético [3], que utilizam o magnetômetro do smartphone do usuário. Entre esses, os IPSs baseados em WLAN, conhecidos como WIPSSs, tem sido os mais estudados devido à fácil acessibilidade à tecnologia Wi-Fi, assim como à eficiência desses sistemas.

Os WIPSSs propostos na literatura são baseados nos padrões IEEE 802.11b/g/n. Nesses sistemas são adotados dois tipos de métodos de localização baseados na potência do sinal recebido (RSS, do inglês *Received Signal Strength*): o método da multilateração [9], que utiliza modelos empíricos de perda de percurso, e o método da *fingerprint* (banco de dados de um *site survey* de um AP) [5], que utiliza algoritmos de reconhecimento de padrões. Nos trabalhos sobre WIPS presentes na literatura são necessários no mínimo 3 APs e 3 *fingerprints* (uma por AP) para se alcançar um erro médio satisfatório [10]. Porém, na prática, muitos estabelecimentos possuem um único AP, e aqueles que possuem mais de um terão seus APs bem distanciados de forma que o sinal de APs distantes podem sofrer fortes flutuações, o que pode prejudicar o desempenho dos WIPSSs.

A. R. L. Paiva, Universidade Federal do Ceará, Fortaleza, CE, Brasil, e-mail: lane.p.l@hotmail.com.

W. C. Freitas, Grupo de Pesquisa em Telecomunicações sem Fio, Universidade Federal do Ceará, Fortaleza, CE, Brasil, e-mail: walter@gtel.ufc.br

I. M. Guerreiro, Grupo de Pesquisa em Telecomunicações sem Fio, Universidade Federal do Ceará, Fortaleza, CE, Brasil, e-mail: igor@gtel.ufc.br

H. J. B. Nascimento, Universidade Federal do Ceará, Fortaleza, CE, Brasil, e-mail: hitalo@gtel.ufc.br

Corresponding author: Antonio Regilane Lima Paiva

Nesse sentido, o objetivo deste trabalho é propor um método de WIPS capaz de estimar a localização 2-D de um usuário com base na *fingerpint* de um único AP. Para esse fim, o método proposto requer que o AP seja de transmissão direcionada. Os padrões Wi-Fi 802.11ac/ax/ad/ay são tecnologias emergentes, da quinta geração de redes locais sem fios, que utilizam transmissão direcionada por meio de técnicas de *beamforming*. A ideia central do nosso método é que cada feixe (transmissão em uma determinada direção) seja visto como um AP, de tal forma que os algoritmos para *fingerpint* já propostos na literatura [5] possam ser adaptados para reconhecerem padrões de RSS de cada feixe que chegam ao UE e, assim, associá-los à sua atual localização. O método proposto foi testado para dois tipos de classificadores: classificador KNN e classificador de Bayes. Simulações numéricas mostraram que o método proposto, sobre um *grid* de 0,50 m de resolução, pode alcançar erro médio de 0,65 m com classificador de Bayes, e erro médio de 0,83 m com classificador KNN.

O resto deste trabalho é organizado com se segue. A Seção II apresenta os trabalhos relacionados. A Seção III resume os conceitos sobre o Wi-Fi de quinta geração com base no padrão 802.11ad. A Seção IV descreve o método proposto e a Seção V detalha os parâmetros de simulação. Finalmente, os resultados numéricos são apresentados na Seção VI e as conclusões na Seção VII.

II. TRABALHOS RELACIONADOS

Estimativa de localização em ambientes fechados baseada em WLAN foi proposto por Paramvir [9]. O seu modelo principal utilizou o classificador KNN (do inglês *K-Nearest Neighbors*) e um banco de dados de medições das RSSs de cada AP levantado por um laptop em algumas coordenadas estratégicas do ambiente. O conjunto de amostras de RSS agrupadas por coordenadas e regiões é conhecido como *fingerpint*, também chamado de mapa de rádio por alguns autores [5]. Os resultados apresentados, considerando o usuário parado, mostraram erro médio de 2 a 3 metros em um ambiente de 978,75 m². Vários trabalhos aprimoraram o trabalho de Paramvir com novas propostas de classificação, tais como modelos probabilísticos, redes neurais artificiais e SVM (*Support Vector Machines*) [11], que alcançaram erros médios inferiores a 2 metros.

Todos esses trabalhos utilizaram de 3 a 20 APs com padrões Wi-Fi de transmissão omnidirecional (Wi-Fi de 1ª a 4ª geração). Porém, com Wi-Fi de transmissão direcionada (Wi-Fi de 5ª geração) é possível estimar a localização do usuário utilizando um único AP. Em [12] é proposto um WIPS baseado em Wi-Fi 802.11ac com esse objetivo. O trabalho utiliza a estimativa de ângulo de chegada (AoA, do inglês *angle of arrival*) e tempo de chegada (ToA, do inglês *time of arrival*) do sinal recebido pelo AP a partir da resposta do canal e considera que a componente de visada direta (LOS, do inglês *line of sight*) sempre existe para o cálculo da distância entre o AP e o UE. Na prática, a componente LOS nem sempre é garantida, e além disso, algoritmos de estimação de AoA possuem, normalmente, alta complexidade computacional. Logo, o uso de *fingerpint* permite a criação de algoritmos de baixa complexidade; ideais para serem executados em dispositivos móveis, e robustos; já que não dependem da componente LOS.

III. PADRÃO WIFI 802.11AD

O padrão Wi-Fi 802.11ad [13] utiliza um *array* de antenas e técnicas de *beamforming* analógico para produzir transmissão direcionada. Tal transmissão se dá pela formação de um padrão de radiação de alta diretividade, chamado de feixe (do inglês *beam*). Na prática, um feixe é identificado por um par de ângulos que representam sua direção: o ângulo azimute e o ângulo de elevação. O conjunto pré-definido desses pares de ângulos é chamado de *codebook*, e indica as direções em que o AP pode transmitir. O padrão 802.11ad opera nas faixas de frequência de 2.4 GHz, 5 GHz e 60 GHz (faixa de ondas milimétricas) e pode suportar um *array* de antenas maior que 10×10 (o número de feixes estreitos depende do número de antenas); e adota SLS (do inglês *Sector Level Sweep*) como método de alinhamento de feixes. O alinhamento de feixes, conhecido como *beamtraining*, trata-se de encontrar os feixes do *codebook* que fornecem os melhores enlaces de comunicação entre o AP e o UE. Num processo conhecido com *beamtracking*, esses melhores feixes são periodicamente testados e selecionados para transmissão de dados, de modo a garantir o melhor alinhamento ao longo do tempo. Na Fig. 1 está representado um exemplo de *beamtracking*. No exemplo, o *beamtraining* seleciona os quatro melhores feixes por busca exaustiva dentro de setores. Para isso, é necessário estimar o canal de cada feixe. Por sua vez, o *beamtracking* seleciona periodicamente, ainda usando a estimativa de canal, o melhor desses quatro feixes para transmissão de dados. Como ilustrado na Fig. 1, o *beamtracking* seleciona B_2 para o UE no instante 01, B_4 no instante 02 e B_3 no instante 03.

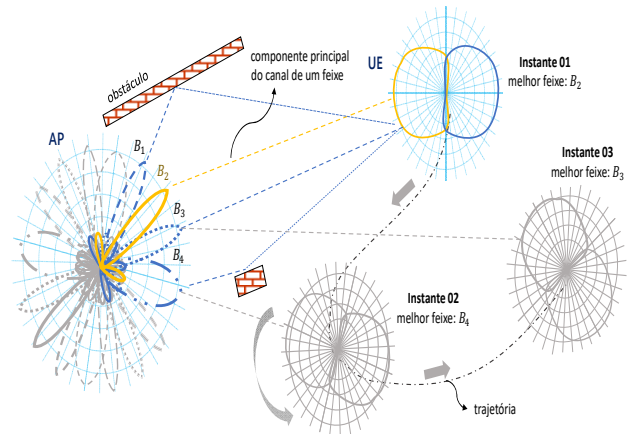


Figura 1. Exemplo de um *beamtracking* para o padrão 802.11ad.

IV. MODELO PROPOSTO

É possível usar o indicador da RSS de cada um desses melhores feixes durante o *beamtracking* e utilizá-los como referências para estimar a localização do UE [14]. Considera-se que o *array* de antenas do UE está configurado com padrão de radiação quase-omnidirecional durante a localização. Mesmo quando não existir visada direta em uma certa localização para um certo feixe, ainda pode ser possível obter a RSS, mesmo que baixa, pois, a reflexão, a difração, o espalhamento e os lóbulos secundários podem garantir a presença de algum nível do sinal. Assim, é possível relacionar cada localização com um conjunto ordenado das RSSs dos feixes e então montar uma *fingerpint*.

Considere um *codebook* de N feixes e que M são os melhores feixes, tal que $M < N$, serão escolhidos no *beamtraining*. Seja \mathcal{M} o conjunto dos M índices dos melhores feixes. Considere também uma *fingerprint* $\mathcal{F} = \{\mathbf{F}, \mathbf{L}\}$, tal que $\mathbf{F} \in \mathbb{R}^{L \times N \times S}$ e $\mathbf{L} \in \mathbb{R}^{L \times 2}$, com L pontos (localizações no ambiente) de coordenadas (x, y) e com S amostras de RSS por ponto, em que uma amostra de RSS é um vetor $\mathbf{r}_{l,s} \in \mathbb{R}^{N \times 1}$ formado pela RSS de cada feixe do *codebook*. Os métodos adotados nesse trabalho são derivados do KNN [5]. Tomando como padrão a *fingerprint* \mathcal{F} , uma amostra de RSS online $\mathbf{s}_x \in \mathbb{R}^{M \times 1}$ coletada periodicamente pelo UE, a partir dos feixes de índices pertencentes a \mathcal{M} , será classificada dentro de K pontos. Foram testados como classificadores a distância euclidiana e os seguintes modelos baseados na regra de Bayes: gaussiano, exponencial e *kernel* normal. A estimativa da localização é feita por meio do centroide desses K pontos. O algoritmo de localização proposto é apresentado no Algoritmo 1. Primeiro, pega-se os índices dos M melhores feixes encontrados pelo *beamtraining*. Em seguida, coleta-se uma amostra de RSS \mathbf{s}_x durante o *beamtracking*. Suponha que a amostra \mathbf{s}_x seja coletada no ponto \mathbf{x} . Então, pega-se as amostras de RSS do tensor \mathbf{F} correspondentes aos M melhores feixes, gerando um tensor reduzido $\mathbf{F}_{\mathcal{M}}$ de forma que $\mathbf{F}_{\mathcal{M}} \in \mathbb{R}^{L \times M \times S}$ e $\mathbf{r}_{l,s} \in \mathbb{R}^{M \times 1}$. Classifica-se \mathbf{s}_x dentro de K linhas da *fingerprint* utilizando um modelo de classificação. Este modelo retorna os índices \mathcal{K} das K localizações mais prováveis e seus respectivos pesos w_k . Por fim, estima-se o ponto \mathbf{x} calculando o centroide dessas K localizações. O Algoritmo 1 é adequado tanto para um usuário estacionário como para um usuário em movimento.

Algoritmo 1. Método de Localização Proposto

Entrada: $\mathcal{F}, \mathbf{s}_x, M, K$

Saída: localização estimada do usuário

início

leia: $\mathcal{F} \leftarrow \text{banco_dados}()$

para um novo beamtraining fazer

leia: $\mathcal{M} \leftarrow \text{beamtraining}()$

$\mathbf{F}_{\mathcal{M}}$ as M colunas de \mathbf{F} de índice \mathcal{M}

para o próximo instante do beamtracking fazer

leia: $\mathbf{s}_x \leftarrow \text{beamtracking}(\mathcal{M})$

$\mathcal{K}, \mathbf{w}_K \leftarrow \text{classificador}(\mathbf{s}_x, \mathbf{F}_{\mathcal{M}}, K)$

$\mathbf{L}_{\mathcal{K}} \leftarrow$ as K linhas de \mathbf{L} de índice \mathcal{K}

$\hat{\mathbf{x}} \leftarrow \text{centroide}(\mathbf{L}_{\mathcal{K}}, \mathbf{w}_K)$

se um novo beamtraining ocorrer então

quebrar laço

fim_se

fim_para

fim_para

fim

Classificador baseado em norma (KNN): uma norma pode ser utilizada para calcular a similaridade de \mathbf{s}_x com cada amostra $\mathbf{r}_{l,s}$ da matriz de médias $\bar{\mathbf{F}} \in \mathbb{R}^{L \times M}$ obtida do tensor \mathbf{F}

pela média ao longo da dimensão S . Então, escolhe-se os K pontos correspondentes as K menores normas. Foi adotada a norma euclidiana e o peso de cada ponto foi o inverso da própria norma calculada. A Fig. 2 ilustra o algoritmo de localização proposto com norma euclidiana.

Classificador baseado na regra de Bayes: considere que cada elemento s_m do vetor \mathbf{s}_x tenha uma probabilidade $p_{l,m}$ de pertencer ao feixe m no ponto \mathbf{p}_l da *fingerprint*. Então, a probabilidade do vetor \mathbf{s}_x pertencer a um ponto \mathbf{p}_l é dada por:

$$p(\mathbf{s}_x | \mathbf{p}_l) = \prod_{m=1}^M p_{l,m} \quad (1)$$

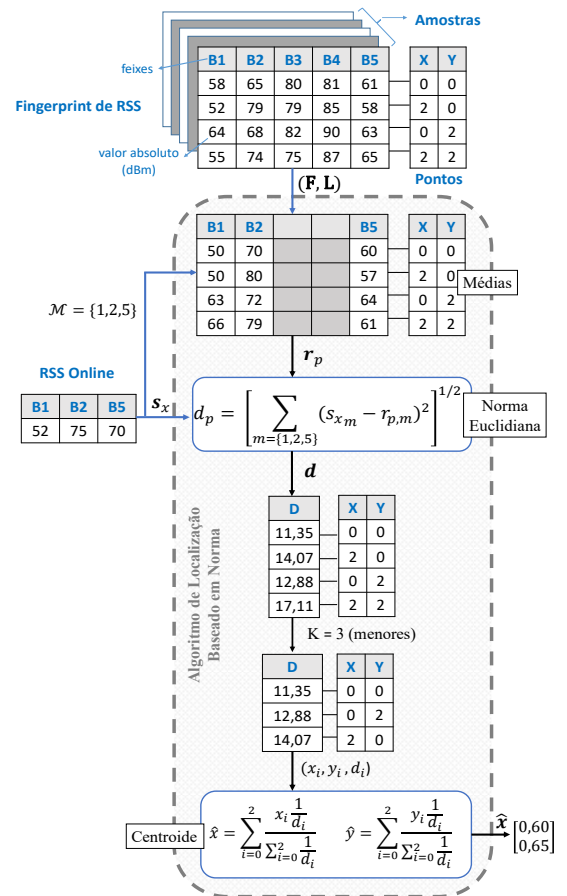


Figura 2. Ilustração do método de localização por KNN utilizando norma euclidiana para $N = 5$, $M = 3$, $L = 4$ e $K = 3$.

A probabilidade $p_{l,m}$ foi estimada do vetor de amostras $\mathbf{r}_{l,s} \in \mathbb{R}^{S \times 1}$ do tensor \mathbf{F} da *fingerprint* utilizando o próprio histograma e modelos de aproximação de histogramas. Foram testados os seguintes modelos de aproximação:

Modelo Gaussiano

$$p_{l,m}(x) = \frac{1}{\sqrt{2\pi\sigma_{l,m}^2}} \exp \left[-\frac{(x - \bar{r}_{l,m})^2}{\sigma_{l,m}^2} \right] \quad (2)$$

Modelo Exponencial

$$p_{l,m}(x) = \frac{1}{2} e^{-|x - \bar{r}_{l,m}|} \quad (3)$$

Modelo de Estimação de Densidade por Kernel

$$p_{l,m}(x) = \frac{1}{Sh} \sum_{s=1}^S \mathcal{K} \left(\frac{x - \bar{r}_{l,m,s}}{h} \right) \quad (4)$$

em que $\bar{r}_{l,m}$ e $\sigma_{l,m}^2$ é a média e a variância do vetor $\mathbf{r}_{l,m}$, respectivamente, $\mathcal{K}(\cdot)$ é a função do *kernel* e $h > 0$ é o parâmetro de suavização.

Usando regras de Bayes, temos que a probabilidade do usuário estar no ponto \mathbf{p}_l dado que foi coletado \mathbf{s}_x é:

$$p(\mathbf{p}_l | \mathbf{s}_x) = \frac{p(\mathbf{s}_x | \mathbf{p}_l) p(\mathbf{p}_l)}{p(\mathbf{s}_x)} \quad (5)$$

em que $p(\mathbf{s}_x | \mathbf{p}_l)$ é a verossimilhança, $p(\mathbf{p}_l)$ é a probabilidade *a priori* e $p(\mathbf{s}_x)$ é uma constante de normalização. A probabilidade *a priori* $p(\mathbf{p}_l)$ pode ser definida como a probabilidade de encontrar um usuário numa região \mathcal{R} , tal que $\mathbf{p}_l \in \mathcal{R}$. Por exemplo, é mais provável encontrar um usuário em torno de uma mesa do que no canto de uma sala. Se essas regiões não forem levadas em consideração, $p(\mathbf{p}_l)$ pode ser considerada uniforme e então:

$$p(\mathbf{p}_l | \mathbf{s}_x) \propto p(\mathbf{s}_x | \mathbf{p}_l) \quad (6)$$

Com base na relação (6), o algoritmo proposto escolhe os K pontos de maior probabilidade $p(\mathbf{s}_x | \mathbf{p}_l)$. Adotou-se, neste trabalho, como peso de cada ponto a própria probabilidade $p(\mathbf{s}_x | \mathbf{p}_l)$.

V. CENÁRIO DE SIMULAÇÃO

As simulações foram implementadas em Matlab 2015a utilizando o modelo de canal QuaDRiGa 2.0.0 [15]. Os parâmetros de simulação são resumidos a seguir:

- **Canais:** modelo de canal 3D baseado no 3GPP (do inglês *The 3rd Generation Partnership Project*) gerado com QuaDRiGa 2.0.0 numa frequência central de 60 GHz. Foi utilizado potência de transmissão de 1 W. A potência máxima recebida foi de -10 dB e a mínima de -100 dB.
- **AP:** possui um *array* planar de antenas 8×8 espaçadas por um quarto do comprimento de onda. Foram simulados 128 feixes com ângulos de azimute e elevação de -75 a 75°, de 15 em 15° (exemplo de um padrão de radiação gerado é mostrado na Fig. 3); altura: 2,5 m.
- **UE:** uma antena omnidirecional; altura: 1,3 m.

- **Cenário:** ambiente fechado de 100 m² baseado no cenário mmMAGIC Indoor. No ambiente criado há 7 regiões onde não se prevalece a componente com LOS. O ambiente é formado por um *grid* de 441 pontos, onde cada ponto do *grid* representa uma região quadrada de 50×50 cm (Fig. 4).
- **Fingerprint:** levantada em um *grid* 2D de 221 pontos distribuídos como um tabuleiro de xadrez; foram geradas 20 amostras de RSS por ponto; dimensão do tensor de RSS da *fingerprint*: 221×128×20.
- **Classificadores:** para todos os modelos foi adotado $K = 4$. As configurações de cada modelo estão listadas na Tabela 1.




Figura 3. Padrão de feixe com -16° de elevação e 45° de azimute.

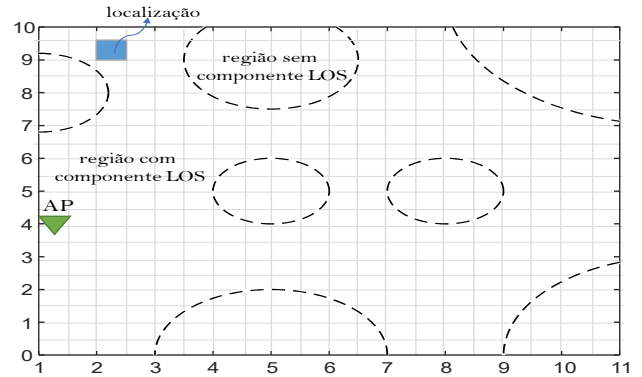


Figura 4. Ambiente fechado utilizado nas simulações. O ambiente de 10×10 m possui 7 regiões de somreamento (círculos tracejados), 441 localizações (quadrados) e 1 AP (triângulo).

TABELA I
CONFIGURAÇÃO DOS MODELOS ADOTADOS.

Modelo	Configuração
KNN	norma euclidiana
Histograma	número de bins = 10
Kernel	núcleo: normal h = 2,2 número de bins = 100
Gaussiano	-
Exponencial	-

VI. RESULTADOS E DISCUSSÃO

Os testes foram efetuados nos 441 pontos do *grid* para um usuário estacionário com novas realizações de canais. A métrica de desempenho adotada foi o erro médio (EM), dado pela média das distâncias euclidianas entre os pontos estimados e os verdadeiros pontos de localização.

A primeira simulação de desempenho foi a influência do número de feixes (valor de M) usado. Uma vez que a classificação depende diretamente da discriminância entre as amostras de RSS, o número de feixes, que dá a dimensão do vetor de amostras, influencia no desempenho do método adotado. A Fig. 5 mostra que o EM tende a diminuir à medida que o número de feixes aumenta, alcançando um estado de saturação em torno de 120 feixes. Para o modelo do *kernel*, utilizando 8 feixes, alcançou-se um EM de 2,50 m. Para 64 feixes, o EM obtido com *kernel* cai para 1,51 m e para 120 feixes o EM se mantém em mais ou menos 0,65 m. Também notou-se que o modelo exponencial começa a falhar (indefinição numérica no cálculo do centroide devido a valores de peso nulos) a partir de 97 feixes. Uma vez que o modelo exponencial decresce rapidamente em torno da média, pode-se dizer, pela Equação (1), que o aumento do número de feixes faz com que esse modelo produza probabilidades de verossimilhança quase nulas.

Na segunda simulação, foram analisadas as estatísticas para $M = 8$ (teste com poucos feixes no *beamtracking*) e $M = 120$ (teste com muitos feixes no *beamtracking*). As Tabelas II e III apresentam algumas estatísticas obtidas. Os processos de *beamtracking* normalmente utilizam poucos feixes para não sobrecarregarem o canal, sendo bem menor para arquiteturas *beamforming* analógicas. O modelo do *kernel*, como mencionado antes, apresentou o melhor desempenho, com EM de 2,5 m e desvio padrão 2,1 m, tendo no melhor caso uma estimativa exata (erro de 0 m) e no pior caso um erro de 10 m, garantindo em 50% dos testes erro inferior a 2 m. Os demais modelos apresentaram desempenhos parecidos, com EMs inferiores a 3 m. Utilizando 120 feixes no *beamtracking*, o EM do modelo baseado em *kernel* cai para 0,65 m, sendo que em 92% dos testes o EM está abaixo de 2 m. Nota-se que o modelo exponencial gerou os melhores resultados, alcançando um EM de 0,41 m, valor bem menor que os demais modelos. Porém, em termos de falha, o modelo exponencial foi inferior, falhando em 22,6% dos testes, enquanto os demais foram robustos nesse sentido.

O modelo gaussiano e histograma geraram resultados bem parecidos com o *kernel*, sendo que o modelo gaussiano apresenta a vantagem de possuir custo computacional menor. Por último, o KNN, o algoritmo de mais baixa complexidade, gerou o maior EM, com valor de 0,83 m, que ainda é um resultado satisfatório para WIPSSs. As Fig. 6 e 7 mostram os desempenhos dos modelos em termos de CDF (*Cumulative Distribution Functions*) do erro médio, onde, para $M = 8$, pode-se notar uma probabilidade de mais ou menos 60% do sistema apresentar erros inferiores a 3 m e de mais ou menos 45% de apresentar erros inferiores a 2 m, enquanto que, para $M = 120$, há uma probabilidade de quase 100% do sistema apresentar erros inferiores a 2 m. Pela CDF, também é possível

ver que o modelo baseado em *kernel* foi o melhor entre os modelos analisados.




Figura 5. Influência do número de feixes no erro médio.

TABELA II
INDICADORES DE DESEMPENHO PARA $M = 8$.

	EM*	DP	Min.	Max.	< 2 m	NF
KNN	2,79	2,21	0	11,86	44,9	0
Gauss.	2,66	2,13	0	10,66	45,1	0
Hist.	2,78	2,13	0	10,69	44,7	0
Exp.	2,83	2,48	0	11,79	47,4	0
Kernel	2,51	2,11	0	10,00	49,7	0

*EM: erro médio; DP: desvio padrão; Min: mínimo; Max: máximo; < 2 m: proporção de erros abaixo de 2 m (%); NF: número de falhas (%).

TABELA III
INDICADORES DE DESEMPENHO PARA $M = 120$.

	EM*	DP	Min.	Max.	< 2 m	NF
KNN	0,83	0,78	0	6,75	93,8	0
Gauss.	0,66	0,95	0	6,80	92,5	0
Hist.	0,69	0,94	0	5,59	91,6	0
Exp.	0,41	0,64	0	4,03	95,9	22,6
Kernel	0,65	0,93	0	5,59	92,2	0

*EM: erro médio; DP: desvio padrão; Min: mínimo; Max: máximo; < 2 m: proporção de erros abaixo de 2 m (%); NF: número de falhas (%).




Figura 6. CDF (*Cumulative Distribution Functions*) do erro médio para $M = 8$.




Figura 7. CDF (Cumulative Distribution Functions) do erro médio para $M = 120$.

VII. CONCLUSÃO

Na literatura, os trabalhos sobre WIPs baseados em *fingerprint* abordam métodos de localização 2-D de um usuário com base nas *fingerprints* de mais de 3 APs com transmissão omnidirecional. Este trabalho contribui com um método de WIPs capaz de estimar a localização 2-D de um usuário com base na *fingerprint* de único AP com tecnologia *beamforming*, tecnologia presente na quinta geração de Wi-Fi.

O método foi testado para o classificador KNN e para os classificadores de Bayes com histograma, modelo Gaussiano, exponencial e *kernel* normal. As simulações foram realizadas sobre um *grid* de 0,50 m de resolução. Foi mostrado que os desempenhos dos métodos crescem com o número de feixes adotados no processo de *beamtracking*, até saturarem em torno de 120 feixes. Entre os modelos testados, destacam-se o modelo *kernel* e Gaussiano, que apresentaram os melhores resultados, com erro médio de 0,65 m para 128 feixes sem falhas de localização. Já modelo exponencial apresentou erro médio de 0,41 m para 128 feixes, mas com uma probabilidade de falha de 22,6 %.

Como conclusão geral, os modelos de localização propostos mostraram desempenho satisfatório para um usuário estacionário, com erro médio inferior a 2,5 m utilizando poucos feixes e com erro médio entre 0,4 a 0,8 m utilizando em torno de 120 feixes. Tais resultados são tão bons quanto os métodos de WIPs que empregam 3 ou mais APs.

Avaliação e desenvolvimento do modelo proposto para o UE com transmissão direcionada e para o usuário em movimento, além de testes empíricos, são propostas para trabalhos futuros.

AGRADECIMENTOS

Agradecemos à Coordenação de Aperfeiçoamento de Pessoal de Nível Superior (CAPES) pela bolsa de estudo de Antônio Paiva, ao Conselho Nacional de Desenvolvimento Científico e Tecnológico (CNPq) pela bolsa de pós-doutorado de Igor Guerreiro (processo nr. 151004/2017-0) e ao Grupo de Pesquisa em Telecomunicações sem Fio (GTEL) pelo apoio e conhecimento compartilhado.

REFERÊNCIAS

- [1] R. L. Paiva, F. R. P. Cavalcanti, and H. J. Nascimento, "Avaliação de algoritmos de localização indoor baseados em mapa de assinatura de WLANs," *XXXIV Simpósio Brasileiro De Telecomunicações (SBTr)*, Santarém, Brasil, vol. 30, 2016.
- [2] Hammoud, M. Deriaz, and D. Konstantas, "Robust ultrasound based room-level localization system using cots components," in *Ubiquitous Positioning, Indoor Navigation and Location Based Services (UPINLBS), 2016 Fourth International Conference on*, pp. 11–19, 2016.
- [3] V. Pasku, A. De Angelis, G. De Angelis, D. D. Arumugam, M. Dionigi, P. Carbone, A. Moschitta, and D. S. Ricketts, "Magnetic field based positioning systems," *IEEE Communications Surveys & Tutorials*, 2017.
- [4] N. U. Hassan, A. Naeem, M. A. Pasha, T. Jadoon, and C. Yuen, "Indoor positioning using visible led lights: A survey," *ACM Computing Surveys (CSUR)*, vol. 48, no. 2, p. 20, 2015.
- [5] V. Honkavirta, T. Perala, S. Ali-Loytty, and R. Piché, "A comparative survey of WLAN location fingerprinting methods," in *Positioning, Navigation and Communication, 2009. WPNC 2009. 6th Workshop on*, pp. 243–251, 2009.
- [6] J. Krumm, S. Harris, B. Meyers, B. Brumitt, M. Hale, and S. Shafer, "Multi-camera multi-person tracking for easy living," in *Visual Surveillance, 2000. Proceedings. Third IEEE International Workshop on*, pp. 3–10, 2000.
- [7] P. Barsocchi, F. Potorti, and P. Nepa, "Device-free indoor localization for AAL applications," in *Wireless Mobile Communication and Healthcare*. Springer, pp. 361–368, 2012.
- [8] F. Mazhar, M. G. Khan, and B. Sällberg, "Precise indoor positioning using UWB: A review of methods, algorithms and implementations," *Wireless Personal Communications*, pp. 1–25, 2017.
- [9] P. Bahl and V. N. Padmanabhan, "Radar: An in-building RF-based user location and tracking system," in *INFOCOM 2000. Nineteenth Annual Joint Conference of the IEEE Computer and Communications Societies Proceedings. IEEE*, vol. 2, pp. 775–784, 2000.
- [10] A. Khalajmehrabadi, N. Gatsis, and D. Akopian, "Modern WLAN fingerprinting indoor positioning methods and deployment challenges," *IEEE Communications Surveys & Tutorials*, 2017.
- [11] H. Liu, H. Darabi, P. Banerjee, and J. Liu, "Survey of wireless indoor positioning techniques and systems," *IEEE Transactions on Systems, Man, and Cybernetics, Part C (Applications and Reviews)*, vol. 37, no. 6, pp. 1067–1080, 2007.
- [12] F. Wen and C. Liang, "Fine-grained indoor localization using single access point with multiple antennas," *IEEE Sensors Journal*, vol. 15, no. 3, pp. 1538–1544, 2015.
- [13] I. S. Association et al., "802.11-2012-IEEE standard for information technology-telecommunications and information exchange between systems local and metropolitan area networks-specific requirements part 11: Wireless LAN medium access control (MAC) and physical layer (PHY) specifications," *IEEE Std*, vol. 802, 2012.
- [14] M. Vari and D. Cassioli, "mmwaves RSSI indoor network localization," in *Communications Workshops (ICC), 2014 IEEE International Conference on*, pp. 127–132, 2014.
- [15] S. Jaeckel, L. Raschkowski, K. Borner, and L. Thiele, "Quadriga: A 3-D multi-cell channel model with time evolution for enabling virtual field trials," *IEEE Transactions on Antennas and Propagation*, vol. 62, no. 6, pp. 3242–3256, 2014.



Antonio Regilane Lima Paiva received the B.Sc. in Teleinformatic Engineering from Federal University of Ceará (UFC), Brazil in 2016. He is currently pursuing the M.Sc. degree in Teleinformatic Engineering from the same university. His main area of interest concerns signal and image processing, pattern recognition, embedded systems and wireless communication systems.



Walter da Cruz Freitas Jr received his PhD degree in Teleinformatic Engineering from Federal University of Ceará (UFC), Brazil in 2006 and his B.S. and M.S. degrees in Electrical Engineering from the same university. He is currently an Assistant Professor with the Department of Teleinformatics Engineering of the Federal University of Ceará and researcher of Wireless Telecom Research Group

(GTEL). His main area of interest concerns features development to improve the performance of the wireless communication systems, interference avoidance tools, multilinear algebra, and tensor-based signal processing applied to communications.



Igor Moaco Guerreiro received the B.S., M.S. and Ph.D. degrees in Teleinformatics Engineering from the Federal University of Ceará (UFC), Brazil, in 2007, 2010 and 2016, respectively. He currently holds a post-doc position at the UFC Department of Teleinformatics Engineering. Some topics of his research interests include techniques for MIMO transceiver design, strategies for distributed optimization for wireless communication systems, modeling and simulation of cellular

communication, dynamic spectrum access methodologies and physical layer aspects for Internet of Things.



Hitalo Joseferson Batista Nascimento received the M.S. degrees in Computer Science from the State University of Ceará (UECE), Brazil, where he was Researcher of the CAPES and the Laboratory of Optimization and Industrial Management (Login). He currently holds a PhD position at the UFC Department of Teleinformatics Engineering. His research interests include Machine Learning, Pattern

Recognition, Applied Statistics, Queue Theory and Wireless Communication.